

Documentação do Projeto: MVP Machine Learning & Analytics

Contexto Geral

Este documento consolida as definições iniciais exigidas para o Minimum Viable Product (MVP) da sprint de Machine Learning & Analytics da PUC-Rio. O projeto foca na predição de vazão na indústria de Óleo e Gás (O&G), aplicando algoritmos preditivos para otimização de ativos logísticos e de produção.

1. Escolha da Base de Dados

A base de dados escolhida é o **Volve Production Data**, um conjunto de dados reais de produção offshore disponibilizado publicamente pela petroleira norueguesa Equinor para fins de pesquisa e desenvolvimento acadêmico.

A extração utilizada é a aba *Daily Production Data*, que compila as medições diárias de sensores de fundo de poço e superfície. O carregamento será feito diretamente via URL pública (formato *raw*) do GitHub, garantindo a reprodutibilidade integral do código sem necessidade de configurações locais de acesso, conforme os requisitos da disciplina.

2. Definição do Problema

- **Problema Escolhido:** Estimação da vazão de produção diária de óleo em poços de petróleo a partir de medições de sensores operacionais de pressão e temperatura.
- **Objetivo do Modelo:** Desenvolver um modelo de **Regressão** capaz de prever o volume de óleo produzido, auxiliando no monitoramento da saúde do poço e na identificação de anomalias operacionais (como falhas em sensores ou restrições de fluxo).
- **Variável-Alvo (Target):** BORE_OIL_VOL (Volume Diário de Óleo Produzido).
- **Por que usar Machine Learning:** A relação termodinâmica e fluidodinâmica entre as pressões (fundo de poço, cabeça do poço), as temperaturas e a vazão multifásica resultante é inerentemente complexa e não-linear. Modelos preditivos de ML conseguem mapear esses padrões com alta precisão, substituindo heurísticas puramente analíticas.
- **Premissas e Hipóteses:**
 - Assume-se que as leituras dos sensores operacionais (pressão, temperatura, abertura do *choke*) são indicadores diretos e suficientes da dinâmica de escoamento.
 - Dias com horas de operação nulas (ON_STREAM_HRS = 0) resultarão em vazão nula.
 - Dados nulos ou zerados em sensores específicos podem indicar falhas de instrumentação que exigirão tratamento rigoroso na etapa de preparação de dados.

3. Estrutura Esperada do Notebook

3.1. Apresentação do Problema

No contexto da engenharia de produção e logística do setor de energia, antecipar o comportamento dinâmico de poços e dutos é fundamental para a transição energética e a eficiência de ativos. O MVP visa construir um pipeline analítico reproduzível que ingere dados de telemetria offshore, trata inconsistências comuns a ambientes severos e aplica algoritmos de regressão para estimar a produtividade do ativo (*well performance*). A tarefa central é de **Regressão** supervisionada.

3.2. Apresentação dos Dados

O dataset **Volve Production Data (Daily)** captura o histórico operacional de poços de um campo no Mar do Norte.

- **Fonte:** Equinor (Repositório aberto do Campo de Volve).
- **Quantidade de Registros:** 15.634 linhas.
- **Quantidade de Atributos:** 24 colunas.
- **Principais Variáveis Preditoras (Features):**
 - ON_STREAM_HRS: Horas de operação do poço no dia.
 - AVG_DOWNHOLE_PRESSURE: Pressão média de fundo de poço.
 - AVG_DOWNHOLE_TEMPERATURE: Temperatura média de fundo de poço.
 - AVG_DP_TUBING: Diferencial de pressão na tubulação.
 - AVG_CHOKE_SIZE_P: Percentual de abertura da válvula (choke).
 - AVG_WHP_P: Pressão na cabeça do poço (Wellhead Pressure).
- **Identificação da Variável-Alvo:** BORE_OIL_VOL.
- **Limitações do Dataset:** Forte presença de valores ausentes devido a períodos de inatividade do poço ou falha pontual de telemetria nos sensores de fundo. Será necessário um tratamento criterioso de *missing values* para evitar o descarte de informações relevantes.